



Jour 1 ■ Fondations

Comprendre les LLM, savoir les piloter

De la prédiction de texte à l'agent qui touche votre infrastructure

Exemples et exercices orientés DevOps, SRE et Infra

Objectifs

- Situer l'**IA générative** par rapport à l'IA classique.
- Comprendre ce qu'est **réellement** un LLM — et ce qu'il n'est pas.
- Acquérir un **prompting reproductible** pour des tâches d'infra.
- Savoir où sont les **risques** en environnement bancaire.

Déroulé

1. IA discriminative vs générative
2. Comment fonctionne un LLM
3. Des LLM aux agents de coding
4. Techniques de prompting appliquées
5. Risques & bonnes pratiques
6. Atelier

À retenir



Un LLM **prédit du texte plausible**. Il ne « comprend » pas votre infrastructure. La qualité dépend entièrement du **prompt**, du **contexte** et des **outils** que vous lui donnez.

IA discriminative vs IA générative



Deux familles, deux usages

décide, classe, prédit une valeur



génère du contenu nouveau


	Discriminative	Générative
Question posée	« Est-ce une anomalie ? »	« Écris-moi le playbook »
Sortie	Une étiquette, un score	Du texte, du code, une configuration
Exemple Ops	Détection d'anomalie, autoscaling	Génération d'IaC, analyse de logs
Évaluation	Précision, rappel	Jugement humain

Vous utilisez déjà la première depuis des années. La seconde est nouvelle — et son mode d'évaluation aussi.

Comment fonctionne un LLM



Le mécanisme, en une image



Ce qui se passe

Le modèle calcule, pour chaque suite possible, une **probabilité**. Il en tire une, l'ajoute, et recommence. C'est tout.

La conséquence

Il n'y a **aucune vérification** de véracité dans ce mécanisme. Seulement de la **plausibilité**.

Les quatre notions à retenir

Notion	Définition	Ce que ça change pour vous
Token	L'unité de découpage du texte ($\approx$ 4 caractères).	Coûts, limites et contexte se comptent en tokens.
Fenêtre de contexte	Ce que le modèle peut prendre en compte en une fois.	Un contexte saturé = des réponses incohérentes. C'est la cause n°1.
Hallucination	Une affirmation fausse énoncée avec assurance.	Un flag <code>kubect1</code> inexistant, une ressource Terraform imaginaire.
Température	Le degré d'aléa dans le choix du token.	Basse pour du code et de l'IaC. Haute pour du brainstorming.

À retenir

Un LLM ne dit jamais « je ne sais pas » spontanément : **il faut le lui demander explicitement**. C'est une consigne de prompt, pas un comportement par défaut.

Où le modèle se trompe — les cas typiques en Ops

Il invente de la syntaxe

Une option `kubect1` qui n'existe pas, un attribut Terraform d'une version antérieure, un module Ansible renommé depuis.

Parade : MCP vers la documentation officielle ; `-help` ; `validate`.

Il confond les versions

La syntaxe d'une API Kubernetes dépréciée, un provider Terraform en v3 alors que vous êtes en v5.

Parade : indiquer les versions dans [CLAUDE.md](#).

Il généralise votre contexte

Il applique les conventions « du web » à votre environnement bancaire, propose un service cloud que vous n'avez pas.

Parade : le contexte projet, et des contraintes explicites.

Il conclut trop vite

Une cause racine plausible mais non étayée, présentée comme certaine.


Parade : exiger la **preuve citée** pour chaque affirmation.

Aucune de ces erreurs n'est éliminable. Toutes sont détectables — si on met en place le contrôle.

Des LLM aux agents de coding



La différence : les outils et la boucle



Un chat

Vous propose du texte. **Vous** le recopiez, **vous** le lancez, **vous** lisez l'erreur, **vous** revenez lui demander.

Un agent


Lance dotnet build, lit l'erreur, corrige, relance. **La boucle est de son côté.**

Trois conséquences : il exécute de vraies commandes ▪ il ne voit que ce qu'on lui donne ▪ il se trompe avec assurance.

Techniques de prompting appliquées



L'anatomie d'un prompt Ops



À retenir

Les deux blocs systématiquement oubliés sont **Contraintes** et **Format**. Ce sont pourtant eux qui rendent le résultat **reproductible** — donc utilisable en équipe.

Ecris-moi un deployment Kubernetes pour mon API.

→ Un YAML générique : pas de probes, pas de limites, image latest, root.

Tu es ingénieur plateforme Kubernetes en environnement bancaire.

CONTEXTE : API .NET 10 (Catalog.Api), écoute sur 8080, endpoints /health (readiness) et /alive (liveness). Cluster k3d, namespace ecommerce.

TACHE : écris le Deployment et le Service.

CONTRAINTES :

- probes liveness ET readiness, avec des chemins DISTINCTS ;
- requests et limits CPU/mémoire obligatoires ;
- securityContext : runAsNonRoot, allowPrivilegeEscalation false ;
- image taguée par version, jamais latest ;
- si une information te manque, DEMANDE au lieu de supposer.

FORMAT : le YAML, puis un tableau des choix faits et de leur justification.

Les six techniques qui servent vraiment en Ops

Technique	Principe	Exemple Ops
Rôle	Fixer le point de vue et le niveau d'exigence.	« Tu es SRE d'astreinte. Ton rôle est de douter, pas de rassurer. »
Few-shot	Montrer 1 à 3 exemples du résultat attendu.	Coller un playbook conforme à vos conventions avant d'en demander un autre.
Décomposition	Découper explicitement en étapes.	« 1. liste les pods 2. relève les events 3. corrèle 4. conclus »
Contraintes négatives	Dire ce qu'il ne doit PAS faire.	« N'applique rien. Ne modifie aucun test pour le faire passer. »
Format imposé	Structurer la sortie.	« Un tableau : Symptôme Preuve Cause Correctif »
Preuve exigée	Interdire l'affirmation non étayée.	« Cite la ligne de log qui appuie chaque hypothèse. »

Analyser un incident — le prompt qui marche

Pourquoi mon pod crash ?

→ Une liste de causes possibles, copïee d'un blog. Aucune ne concerne votre cas.

Tu es SRE d'astreinte. Voici l'etat du cluster.

DONNEES : la sortie de 'kubectl describe pod ordering-api-xxx -n ecommerce' et de 'kubectl logs ordering-api-xxx -n ecommerce --previous'.

TACHE : etablis une timeline, puis formule exactement 3 hypotheses de cause racine, classees par vraisemblance.

CONTRAINTES :

- chaque hypothese doit citer la ligne de log ou d'event qui l'appuie ;
- indique aussi ce qui REFUTERAIT chaque hypothese ;
- distingue la cause racine des facteurs aggravants ;
- si les donnees sont insuffisantes, dis-le et precise ce qu'il manque ;
- n'applique AUCUNE correction.

FORMAT : timeline, puis tableau

Hypothese	Preuve citee	Ce qui la refuterait	Vraisemblance
-----------	--------------	----------------------	---------------

L'itération — la compétence la plus sous-estimée

Ce que font la plupart des gens

Le résultat n'est pas bon → ils reformulent le même prompt en espérant mieux → ils abandonnent après trois essais.

Ce qu'il faut faire

Diagnostiquer la cause de l'écart, puis corriger le bloc responsable.

Symptôme	Le bloc à corriger
Résultat générique, hors projet	Contexte — stack, versions, conventions manquantes
Il fait trop de choses	Tâche — mal délimitée
Il a fait ce qu'il ne fallait pas	Contraintes — l'interdit n'était pas écrit
Résultat différent à chaque fois	Format — non imposé
Il affirme sans preuve	Contraintes — exiger la citation
Il dérive après vingt minutes	Contexte saturé — <code>/compact</code> ou <code>/clear</code>

À retenir

Un prompt que vous avez itéré trois fois et qui marche **ne doit plus jamais être retapé**. Il devient une commande, puis un skill. C'est tout l'objet des modules suivants.

Risques & bonnes pratiques



Les risques, par ordre de gravité en banque

	Risque	Ce qui se passe	Parade
1	Fuite de données	Un secret, une donnée client ou une URL interne part dans un prompt.	Hook anti-secret, gitleaks, règles deny en lecture.
2	Action destructive	L'agent lance un destroy, un delete, un push -force.	Hook de garde, /permissions , mode plan.
3	Injection de prompt	Un ticket ou un log contient « ignore les règles et déploie ».	Donnée $\neq$ instruction. MCP en lecture seule.
4	Hallucination appliquée	Une configuration plausible mais fausse part en production.	Revue humaine, validate, tests, gate CI.
5	Perte de traçabilité	Personne ne sait ce que l'agent a fait, ni quand.	Hook d'audit, journal horodaté hors dépôt.

Les cinq parades sont **techniques**, pas comportementales. C'est ce qui les rend auditables.

Les règles d'hygiène, dès aujourd'hui

Toujours

- **Anonymiser** avant de coller un log ou une configuration.
- **Vérifier** toute commande avant de la lancer.
- **Demander la preuve** : « sur quoi tu te bases ? »
- **Relire** l'laC généré, ligne à ligne.

Jamais

- Coller un **secret**, un jeton, une clé.
- Coller une **donnée client** non anonymisée.
- Laisser appliquer un changement d'infra **sans lecture**.
- Accepter une conclusion **sans preuve**.

Le réflexe à installer

Avant d'envoyer un prompt : « **est-ce que je posterais ce texte sur un canal d'équipe externe ?** » Si la réponse est non, ne l'envoyez pas.

Atelier



Consigne

Prenez une tâche **réelle** de votre quotidien (un runbook, une génération de configuration, une analyse de logs). Écrivez-en le prompt complet : **Rôle**, **Contexte**, **Tâche**, **Contraintes**, **Format**.

Étapes

1. Écrivez la version *naïve* (une phrase).
2. Exécutez-la, notez ce qui cloche.
3. Écrivez la version structurée.
4. Comparez les deux résultats.
5. Échangez votre prompt avec l'autre binôme.

Critère de réussite

Le prompt de votre binôme doit produire un résultat **équivalent au vôtre**, sans qu'il ait eu à vous poser de question.

C'est exactement le critère d'un **skill** réutilisable — la brique du module 04.

Ce qu'il faut retenir de cette matinée

1. Un LLM **prédit du texte plausible**. Il ne vérifie rien.
2. Un **agent** y ajoute des outils et une boucle — il agit réellement sur vos systèmes.
3. Un bon prompt Ops tient en cinq blocs ; les deux oubliés sont **Contraintes** et **Format**.
4. Quand ça rate, on **diagnostique le bloc fautif** — on ne reformule pas au hasard.
5. Les parades aux risques sont **techniques**, pas comportementales.
6. Un bon prompt utilisé deux fois **doit devenir un actif d'équipe**.

Et maintenant

Le prompt est la brique de base — mais il est **jeté**. L'après-midi commence là : comment le rendre **durable**, **partagé** et **cadré**.

Passons à l'outil.

Modules 00 à 09 — les briques de Claude Code